

统计学习复习大纲

Fw[a]rd, SPFA

2026 年 1 月 14 日

1 统计学习问题分类

监督学习：回归、分类；无监督学习：聚类、变换（降维/投影、嵌入）

2 一元统计分析

极大似然 似然函数： $L(\theta) \prod_i p(x^{(i)}|\theta)$, 最大化似然函数得参数的极大似然估计 θ_{ML} , 常用办法是对似然函数取负对数, 再寻找负对数似然 (NLL) 函数的极小值

贝叶斯法

$$P(\Theta|X^{(1)}, \dots, X^{(n)}) = \frac{P(X^{(1)}, \dots, X^{(n)}|\Theta)P(\Theta)}{P(X^{(1)}, \dots, X^{(n)})} \quad (1)$$

先验和后验属于同一类分布的情况在贝叶斯方法中称为共轭先验, 是贝叶斯方法中设定先验的一种常见做法

评价准则 统计量：样本的函数

一致性：如果随着样本数量的增大，估计量依概率收敛于真实值，即 $\forall \epsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1$ 则称估计量是（弱）一致的。

无偏性：如果估计量的期望等于真实值，即对任意 θ 有 $\mathbb{E}[\hat{\theta}] = \theta$ ，则称估计量是无偏的，否则就是有偏的。将 $\mathbb{E}[\hat{\theta}] - \theta$ 称作估计量的偏差 (bias)。

有效性：估计量的方差应该尽可能小。如果有两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ，且对任意 θ 有 $\mathbb{V}[\hat{\theta}_1] < \mathbb{V}[\hat{\theta}_2]$ ，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。

充分统计量：设总体 X 的概率函数带有未知参数 θ ，统计量 $\hat{\theta} = f(X^{(1)}, \dots, X^{(n)})$ 其中 f 是预定函数，如果条件概率函数 $\mathbb{P}(X^{(1)}, \dots, X^{(n)}|\hat{\theta})$ 与 θ 无关，则称 $\hat{\theta}$ 是 θ 的充分统计量。

因子分解定理 若样本的概率函数能够分解为 $\mathbb{P}(X^{(1)}, \dots, X^{(n)}) = g(x^{(1)}, \dots, x^{(n)})h(f(x^{(1)}, \dots, x^{(n)}); \theta)$ ，则 $\hat{\theta} = f(X^{(1)}, \dots, X^{(n)})$ 是 θ 的充分统计量

指数族分布的充分统计量 若总体服从指数族分布 $P(X) = g(x)h(\theta) \exp(\theta^T \phi(x))$ ，其中 $\phi(x)$ 称为特征基函数，则 $\sum_{i=1}^n \phi(X^{(i)})$ 是 θ 的充分统计量。高斯分布 $\phi(x) = (x^2, x)^T$

最小均方误差估计风险分解 $\mathbb{E}[(\hat{\theta} - \theta)^2] = (\mathbb{E}[\hat{\theta} - \theta])^2 + \mathbb{V}[\hat{\theta} - \theta] = (\mathbb{E}[\hat{\theta}] - \theta)^2 + \mathbb{V}[\hat{\theta}]$ 第一项是估计量的偏差的平方，第二项是估计量的方差。偏差和方差分别反映了估计量的系统误差和随机误差，均方误差最小化同时考虑了系统误差和随机误差。如果将估计量限定为无偏的，则最小均方误差估计量就是一致最小方差无偏估计 (UMVUE)。如果允许估计量有偏，则最小均方误差估计可以不同于 UMVUE。

非参数统计分析 经验分布函数 (EDF): $\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I(x^{(i)} \leq x)$

平滑: $\tilde{F}(x) \triangleq \int_t \hat{F}(t) k(x-t) dt$, k 称为平滑核函数或简称核函数，概率密度函数估计: $\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n k(x - x^{(i)})$

k 近邻 (k-NN) 法: 在实数轴上的每个点 x , 调节区间宽度 $h(x)$ 使得区间 $[x-h(x), x+h(x)]$ 中恰好有 k 个数据，则可用 $\hat{f}(x) = \frac{k}{2nh(x)}$ 来估计密度

3 线性回归

最小二乘法

$$\min_{w,b} \mathcal{E}(w,b) = \min_{w,b} \sum_{i=1}^n (y^{(i)} - (wx^{(i)} + b))^2 \quad (2)$$

$$w_{LS} = \frac{\sum_{i=1}^n (x^{(i)} - \bar{x})(y^{(i)} - \bar{y})}{\sum_{i=1}^n (x^{(i)} - \bar{x})^2}, b_{LS} = \bar{y} - w_{LS}\bar{x} \quad (3)$$

正则化 带约束优化问题:

$$\min_w \sum_i (y^{(i)} - wx^{(i)})^2, s.t. w^2 \leq c \quad (4)$$

$$L(w, \lambda) = \sum_i (y^{(i)} - wx^{(i)})^2 + \lambda(w^2 - c) \quad (5)$$

$$w_{reg} = \frac{\sum x^{(i)} y^{(i)}}{\sum (x^{(i)})^2 + \lambda} \quad (6)$$

正则化是在求最小二乘解的时候限制参数 w 的取值范围，正则化权重越大，取值范围限定得越小。

偏差-方差均衡:

$$\mathbb{E}[\hat{w}] = \frac{\sum (x^{(i)})^2}{\sum (x^{(i)})^2 + \epsilon} w, \mathbb{V}[\hat{w}] = \frac{\sum (x^{(i)})^2 \sigma^2}{(\sum (x^{(i)})^2 + \epsilon)^2} \quad (7)$$

ϵ 越大， $\mathbb{E}[\hat{w}]$ 偏离 w 越多，偏差平方越大； $\mathbb{V}[\hat{w}]$ 越小，方差越小。综合考虑偏差和方差，则可以找到一个合适的 ϵ ，使得两项之和达到最小

贝叶斯: $W \sim N(0, \sigma_w^2), P(Y^{(i)}|W) \sim N(wx^{(i)}, \sigma^2)$, 则 $\epsilon = \sigma^2 / \sigma_w^2$, 正则化项实质上对应于后验分布中由先验分布引入的项

最小二乘回归

$$X = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(n)})^T \end{bmatrix} \quad (8)$$

$$w_{LS} = \arg \min_w (y - Xw)^T (y - Xw) \quad (9)$$

$$X^T y = X^T X w \quad (10)$$

带基函数的回归

$$\Phi \triangleq (f_1, \dots, f_p)^T, y = w^T \Phi(x) \quad (11)$$

$$\Phi^T \Phi w_{LS} = \Phi^T y \quad (12)$$

岭回归

$$\min_w (y - Xw)^T (y - Xw) + \lambda w^T w \quad (13)$$

$$w_{ridge} = (X^T X + \lambda I)^{-1} X^T y \quad (14)$$

贝叶斯线性回归 假设 $P(W) = N(m_0, S_0)$, 样本条件分布如下, 可得

$$P(Y^{(1)}, \dots, Y^{(n)}|W) = \prod N(w^T x^{(i)}, \sigma^2) \quad (15)$$

$$P(W|Y^{(1)}, \dots, Y^{(n)}) = N(m_n, S_n) \quad (16)$$

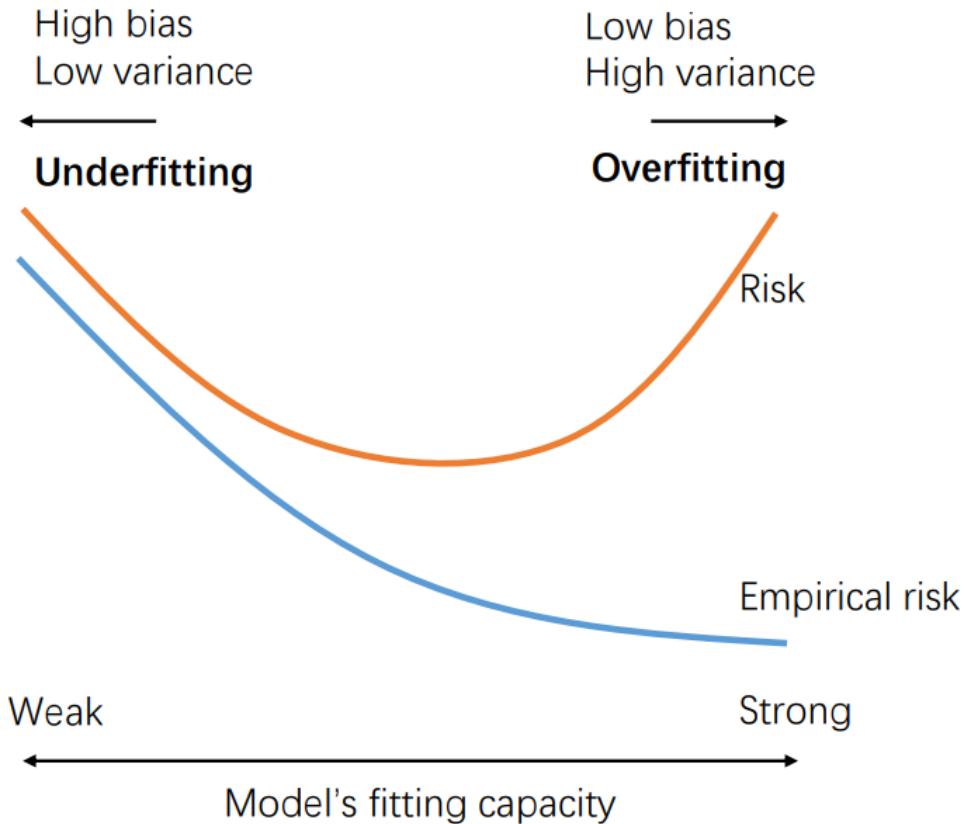
$$m_n = S_n(S_0^{-1}m_0 + \frac{1}{\sigma^2} X^T y) \quad (17)$$

$$S_n = (S_0^{-1} + \frac{1}{\sigma^2} X^T X) \quad (18)$$

序贯学习:

$$\begin{aligned} P(Y^{(1)}, \dots, Y^{(n+1)}|W) &= \\ \frac{P(Y^{(1)}, \dots, Y^{(n)}|W)P(Y^{(n+1)}|W)}{P(Y^{(n+1)}|Y^{(1)}, \dots, Y^{(n)})} & \end{aligned} \quad (19)$$

模型评价与选择 一般来说, 如果模型中可学习参数太少, 模型的拟合能力很弱, 在训练数据上的经验风险很大, 风险也很大, 这种现象称为欠拟合. 经验风险降低但风险反而升高的现象在统计学习中称为过拟合



赤池信息量准则 $AIC = 2NLL + 2p$, 其中, NLL 是训练数据上估计的负对数似然, 是参数的个数. AIC 值越小, 模型越好. 当 p 一定时, 负对数似然越小的回归函数越好, 也就是说极大似然估计是最好的, 代入得 $AIC = n \ln(\mathcal{E}(w_{LS})) + 2p$

贝叶斯模型评价 对参数 (随机变量) 求期望, 称为模型证据

LASSO

$$\min_w (y - Xw)^T (y - Xw) + \lambda \|w\|_1 \quad (20)$$

lasso 回归虽然具有特征选择等优点, 但它一般情况下没有闭式解

核回归

$$\hat{f}(x) \triangleq \sum_{i=1}^n y^{(i)} k(x, x^{(i)}) \quad (21)$$

Mercer 条件: 令矩阵 K , 其中 $K_{ij} = k(x^{(i)}, x^{(j)})$, 要求对任意 x , K 半正定. 有 $k(x, y) = k(y, x)$, $k(x, y) = (\Phi(x))^T \Phi(y)$

$$\hat{f}(x) \triangleq \sum_{i=1}^n y^{(i)} \Phi(x^{(i)})^T \Phi(x) = y^T \Phi \Phi(x) = w^T \Phi(x) \quad (22)$$

K 近邻回归

$$\hat{f}(x) \triangleq \frac{1}{k} \sum_{j=1}^k y^{(n_j)}, s.t. x^{(n_j)} \in N_k(x) \quad (23)$$

4 线性分类**线性分类**

$$y = \text{sign}(w_{LS}^T x + b_{LS}) \quad (24)$$

有 train-test mismatch 问题

zero-one loss/0-1 loss 考虑到 sign 函数, 平方损失函数等价于

$$L(w, b, x, y) \triangleq I(y \neq \text{sign}(w^T x + b)) \quad (25)$$

Fisher 投影 (LDA) 对于 +1 类, v_+ 为均值, $m_+ = w^T v_+$ 为投影后均值, \mathbf{S}_+ 为协方差矩阵, $S_+ = w^T \mathbf{S}_+ w$ 为投影后方差. -1 类同理. 类内方差 $S_w = S_+ + S_-$ 类间方差 $(m_+ - m_-)^2$, 求:

$$\min_w w^T (\mathbf{S}_+ + \mathbf{S}_-) w, s.t. w^T (v_+ - v_-)(v_+ - v_-)^T w \geq C \quad (26)$$

$$w \propto (\mathbf{S}_+ + \mathbf{S}_-)^{-1} (v_+ - v_-) \quad (27)$$

感知机 Perceptron 使用代理损失函数:

$$L(w, b, x, y) \triangleq \max(0, -y(w^T x + b)) \quad (28)$$

使用随机梯度下降 SGD

$$if y_i(w^T x_i + b) < 0 : w = w + \eta y_i x_i, b = b + \eta y_i \quad (29)$$

对偶形式: $w = \sum \alpha_i y_i x_i, b = \sum \alpha_i y_i, \alpha_i \geq 0$, 直接学 α_i

$$if y_i(\sum \alpha_j y_j x_j^T x_i + \sum \alpha_j y_j) < 0 : \alpha_i = \alpha_i + \eta \quad (30)$$

最终分类器为 $\text{sign}(\sum \alpha_i y_i (x_i^T x + 1))$

带基函数感知机

$$if y_i((\sum \alpha_j y_j \Phi(x_j))^T \Phi(x_i)) < 0 : \alpha_i = \alpha_i + \eta \quad (31)$$

最终分类器为 $\text{sign}((\sum \alpha_i y_i \Phi(x_i))^T \Phi(x))$

带核函数感知机

$$if \sum_j \alpha_j y_i y_j k(x_i, x_j) < 0 : \alpha_i = \alpha_i + \eta \quad (32)$$

最终分类器为 $\text{sign}(\sum \alpha_i y_i k(x_i, x))$

交叉熵损失

$$CE(B(p), B(q)) = -p \ln q - (1-p) \ln(1-q) \quad (33)$$

逻辑回归 样本 $(x_i, y_i), y_i \sim B(q_i), q_i = f(x_i; w, b)$, 令

$$q_i = \frac{1}{1 + \exp(-w^T x_i - b)} \triangleq \sigma(w^T x_i + b) \quad (34)$$

$\sigma(x) = \frac{1}{1+e^{-x}}$ + 交叉熵损失 = 逻辑回归

广义逻辑回归 GLR

$$\min_w \sum (-y_i \ln q_i - (1-y_i) \ln(1-q_i)) \quad (35)$$

其中 $q_i = \frac{1}{1+\exp(-w^T \Phi(x_i))}$

分类器为 $y = \text{sign}(-w^T \Phi(x))$

GLR 的解

$$L(w) = \sum (-y_i \ln q_i - (1-y_i) \ln(1-q_i)) \quad (36)$$

$$\nabla L(w) = \sum (q_i - y_i) \Phi(x_i) = \Phi^T (q - y) \quad (37)$$

$$\nabla \nabla L(w) = \sum q_i (1-q_i) \Phi(x_i) \Phi^T (x_i) = \Phi^T R \Phi \quad (38)$$

其中 $R = \text{diag}(q_i(1-q_i))$, 根据牛顿迭代法

$$w^{new} = w^{old} - (\Phi^T R \Phi)^{-1} \Phi^T (q - y) \quad (39)$$

令 $z \triangleq \Phi w^{old} - R^{-1} (q - y)$, 有

$$w^{new} = (\Phi^T R \Phi)^{-1} \Phi^T R z \quad (40)$$

w^{new} 可视为加权最小二乘问题的解

$$\min_w (z - \Phi w)^T R (z - \Phi w) \quad (41)$$

当 q_i 远离 0.5 时权重变低

朴素贝叶斯

$$P(Y = i | X) = \frac{P(Y = i) P(X | Y = i)}{\sum_{i=1}^n P(Y = i) P(X | Y = i)} \quad (42)$$

其中 $P(X | Y = i) = \prod_j P(X_j | Y = i)$

K-NN

$$\hat{f}(x) \triangleq \text{sign}\left(\frac{1}{k} \sum_{j=1}^k y^{(n_j)}\right), \text{s.t. } x^{(n_j)} \in N_k(x) \quad (43)$$

稀疏表示

$$x \approx \sum_{i=1}^n \alpha_i x^{(i)}, s.t. \sum_{i=1}^n I(\alpha_i \neq 0) = k \quad (44)$$

$\alpha = (\alpha_1, \dots, \alpha_n)^T$ 称为 K-稀疏向量, 分类器为

$$\hat{f}(x) \triangleq \text{sign}\left(\frac{1}{k} \sum_{j=1}^k y^{(n_j)}\right), s.t. \alpha_{n_j} \neq 0 \quad (45)$$

解 α :

$$\min_{\alpha} (x - X\alpha)^T (x - X\alpha) + \lambda \|\alpha\|_1 \quad (46)$$

其中 $X = (x^{(1)}, \dots, x^{(n)})$, 把 2-范数换成 1-范数也行

硬边界 SVM 假设数据线性可分, 分类器无误差, 分类边界 $w^T x_i + b = 0$, 则 $y_i = \text{sign}(w^T x_i + b)$, 距离可写为

$$d_i = \frac{|w^T x_i + b|}{\|w\|_2} = \frac{y_i (w^T x_i + b)}{\|w\|_2} \quad (47)$$

最大间隔问题为 $\max_{w,b} \min_i d_i$, 记为

$$\max_{w,b} \gamma(w, b), \gamma(w, b) \triangleq \min_i \frac{y_i (w^T x_i + b)}{\|w\|_2} \quad (48)$$

考虑到 $\forall \alpha > 0, \gamma(\alpha w, \alpha b) = \gamma(w, b)$, 问题化为

$$\max_{w,b} \frac{1}{\|w\|_2}, \min_i y_i (w^T x_i + b) = 1 \quad (49)$$

进一步松弛为

$$\min_{w,b} \frac{1}{2} \|w\|_2^2, s.t. \forall i, y_i (w^T x_i + b) \geq 1 \quad (50)$$

拉格朗日乘子 $\alpha = (\alpha_1, \dots, \alpha_n)^T$, 拉格朗日函数为

$$L(w, b, \alpha) = \frac{1}{2} \|w\|_2^2 + \sum_{i=1}^n \alpha_i (1 - y_i (w^T x_i + b)) \quad (51)$$

KKT 条件为

$$\nabla_w L(w, b, \alpha) = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i \quad (52)$$

$$\frac{\partial}{\partial b} L(w, b, \alpha) = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \quad (53)$$

$$\alpha_i \geq 0, i = 1, \dots, n \quad (54)$$

$$1 - y_i (w^T x_i + b) \leq 0, i = 1, \dots, n \quad (55)$$

$$\alpha_i (1 - y_i (w^T x_i + b)) = 0, i = 1, \dots, n \quad (56)$$

当 $\alpha_i > 0$ 时, 距离满足 $y_i (w^T x_i + b) = 1$, 只有这些点对计算 w 有贡献, 称为支持向量

软边界 SVM 数据通常不线性可分；有时可分，但为扩大间隔，去掉一些.

$$\min_{w,b} \frac{1}{2} \|w\|_2^2, s.t. \sum_{i=1}^n I(y_i(w^T x_i + b) < 1) \leq c \quad (57)$$

用代理损失函数 $\max(1 - y_i(w^T x_i + b), 0)$, 用拉格朗日法

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 + \lambda \sum_{i=1}^n \max(1 - y_i(w^T x_i + b), 0) \quad (58)$$

令 $\xi_i = \max(0, 1 - y_i(w^T x_i + b))$, 再松弛为

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 + \lambda \sum_{i=1}^n \xi_i, s.t. \forall i, \xi_i \geq 1 - y_i(w^T x_i + b), \quad (59)$$

$$\xi_i \geq 0$$

拉格朗日函数为

$$\begin{aligned} L(w, b, \xi, \alpha, \beta) = & \frac{1}{2} \|w\|_2^2 + \lambda \sum_{i=1}^n \xi_i - \sum_{i=1}^n \beta_i \xi_i \\ & - \sum_{i=1}^n \alpha_i (y_i(w^T x_i + b) - 1 + \xi_i) \end{aligned} \quad (60)$$

KKT 条件为

$$\nabla_w L(w, b, \xi, \alpha, \beta) = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i \alpha_i y_i = 0 \quad (61)$$

$$\frac{\partial}{\partial b} L(w, b, \xi, \alpha, \beta) = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \quad (62)$$

$$\frac{\partial}{\partial \xi} L(w, b, \xi, \alpha, \beta) = 0 \Rightarrow \alpha_i + \beta_i = \lambda \quad (63)$$

$$\alpha_i \geq 0, \beta_i \geq 0, i = 1, \dots, n \quad (64)$$

$$\xi_i \geq 1 - y_i(w^T x_i + b), \xi_i \geq 0, i = 1, \dots, n \quad (65)$$

$$\alpha_i (y_i(w^T x_i + b) - 1 + \xi_i) = 0, i = 1, \dots, n \quad (66)$$

$$\beta_i \xi_i = 0, i = 1, \dots, n \quad (67)$$

代掉 β_i , 得

$$\begin{aligned} w &= \sum_{i=1}^n \alpha_i y_i x_i \\ \sum_{i=1}^n \alpha_i y_i &= 0 \\ 0 \leq \alpha_i &\leq \lambda, i = 1, \dots, n \\ \xi_i &\geq 1 - y_i(w^T x_i + b), \xi_i \geq 0, i = 1, \dots, n \\ \alpha_i (y_i(w^T x_i + b) - 1 + \xi_i) &= 0, i = 1, \dots, n \\ (\lambda - \alpha_i) \xi_i &= 0, i = 1, \dots, n \end{aligned} \quad (68)$$

所有距离可分为 3 类

$$\begin{aligned} y_i(w^T x_i + b) > 1 &\Rightarrow \alpha_i = 0, \xi_i = 0 \\ y_i(w^T x_i + b) = 1 &\Rightarrow 0 < \alpha_i < \lambda, \xi_i = 0 \\ y_i(w^T x_i + b) < 1 &\Rightarrow \alpha_i = \lambda, \xi_i > 0 \end{aligned} \quad (69)$$

当 $\alpha_i > 0$ 时, 距离满足 $y_i(w^T x_i + b) \leq 1$, 只有这些点对计算 w 有贡献, 称为支持向量

对偶问题 $\max_{\alpha} \min_{w,b,\xi} L(w, b, \xi, \alpha)$, 由 KKT 条件得

$$\begin{aligned} \max_{\alpha} -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum_{i=1}^n \alpha_i \\ \text{s.t. } 0 \leq \alpha_i \leq \lambda, \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned} \quad (70)$$

分类器为 $y = \text{sign}(\sum_{i=1}^n \alpha_i y_i x_i^T x + b)$, b 由 $0 < \alpha_i < \lambda$ 的支持向量计算得出

带基函数 SVM & 核 SVM

$$\begin{aligned} \min_{w,b} \frac{1}{2} \|w\|_2^2 + \lambda \sum_{i=1}^n \xi_i, \text{s.t. } \forall i, \xi_i \geq 0, \\ \xi_i \geq 1 - y_i(w^T \Phi(x_i) + b) \end{aligned} \quad (71)$$

KKT 条件为:

$$\begin{aligned} w &= \sum_{i=1}^n \alpha_i y_i \Phi(x_i) \\ \sum_{i=1}^n \alpha_i y_i &= 0 \\ 0 \leq \alpha_i &\leq \lambda, i = 1, \dots, n \\ \xi_i &\geq 1 - y_i(w^T \Phi(x_i) + b), \xi_i \geq 0, i = 1, \dots, n \\ \alpha_i(y_i(w^T \Phi(x_i) + b) - 1 + \xi_i) &= 0, i = 1, \dots, n \\ (\lambda - \alpha_i)\xi_i &= 0, i = 1, \dots, n \end{aligned} \quad (72)$$

对偶问题为

$$\begin{aligned} \max_{\alpha} -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \Phi(x_i)^T \Phi(x_j) + \sum_{i=1}^n \alpha_i \\ \text{s.t. } 0 \leq \alpha_i \leq \lambda, \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned} \quad (73)$$

分类器为 $y = \text{sign}(\sum_{i=1}^n \alpha_i y_i \Phi(x_i)^T \Phi(x) + b)$

核函数 $k(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$

序列最小优化算法 SMO 随机选择两个 α_p 和 α_q , 固定其他 α_i , 在(73)中 $\arg \max_{\alpha_p, \alpha_q}$

比较 贝叶斯分类规则: 对于 (X, Y) , 使用 0-1loss, 最佳分类器为

$$\begin{aligned} f^*(x) &= \arg \min_f E_{X,Y}[I(Y \neq f(X))] = \\ &\arg \max_{k \in \{+1, -1\}} P(Y = k | X = x) \end{aligned} \quad (74)$$

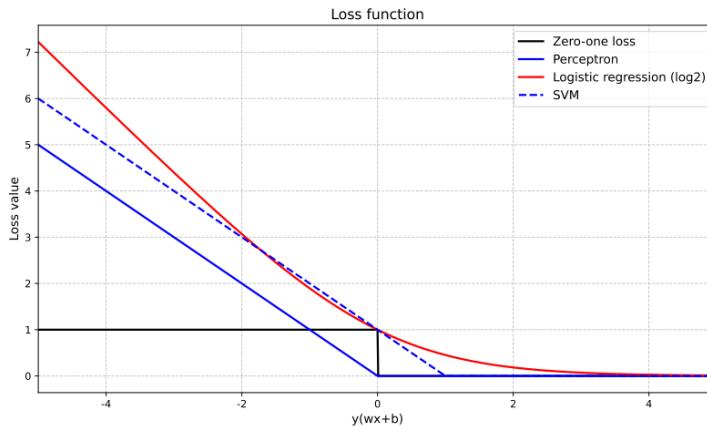
LDA 假设各类服从高斯分布, 协方差矩阵相同

GLR 假设各类服从指数族分布

朴素贝叶斯认为 $P(X|Y) = \prod_j P(X_j|Y)$

K-NN 认为贝叶斯最优分类器在局部是常数

方法	损失函数
感知机	$\max(-y(w^T x + b), 0)$
逻辑回归	$\ln(1 + \exp(-y(w^T x + b)))$
SVM	$\max(1 - y(w^T x + b), 0)$



对 0-1loss 的上界进行优化

$0 - r_{+1} - r_{-1}$ loss +1 类误分损失 r_{+1} , -1 类误分损失 r_{-1}

Precision: $\frac{TP}{TP+FP}$; Recall/TPR: $\frac{TP}{TP+FN}$; FPR: $\frac{FP}{FP+TN}$; F1-value: $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$; ROC 曲线: 以 FPR 为横轴, TPR 为纵轴绘制的曲线; AUC: ROC 曲线下的面积

正则化 考虑到几何解释, SVM 本身就使用 L2 正则化; 逻辑回归自然可以使用 L1 或 L2 正则化; 对于朴素贝叶斯, 可以使用拉普拉斯平滑

基函数和核函数 所有方法均可用基函数 (视作预处理); SVM 和感知机可用核函数; K-NN 可用核函数定义距离

Softmax 回归 设 $P(Y = k) = 1/K$, $P(X|Y = k) = \exp(\theta_k^T \Phi(x))$ 则

$$P(Y = k | X = x) = \frac{\exp(\theta_k^T \Phi(x))}{\sum_l \exp(\theta_l^T \Phi(x))} \quad (75)$$

问题形式为

$$\min_{\theta} - \sum_{i=1}^n \sum_{k=1}^K I(y_i = k) \ln \frac{\exp(\theta_k^T \Phi(x))}{\sum_l \exp(\theta_l^T \Phi(x))} \quad (76)$$

分类器为 $y = \arg \max_k \theta_k^T \Phi(x)$

带温度 Softmax

$$\text{softmax}(z_k, \tau) = \frac{\exp(z_k/\tau)}{\sum_l \exp(z_l/\tau)} \quad (77)$$

sigmoid 为 sign 的 soft 版本, softmax 为 $I(z_k = \max_k z_k)$ 的 soft 版本. τ 越小, softmax 越接近后者. 模拟退火先用大 τ , 再慢慢减小

5 无监督学习

维度诅咒 高维空间中难以估计(概率)密度: 样本数不够; 邻居太远; 距离难分辨. 若样本数为 n^p 则无问题, 但难以承担

降维/投影 $x_i \in \mathbb{R}^p$ 寻找映射 $f: \mathbb{R}^p \rightarrow \mathbb{R}^k$, $p < k$

解决维度灾难; 减少数据量及计算成本; 去噪声及无关特征, 避免过拟合

PCA 先中心化, 再用平方损失寻找投影 $f(x) = Ex$, $E \in \mathbb{R}^{p \times k}$ 反投影 $g(z) = Dz$, $D \in \mathbb{R}^{k \times p}$

$$(E^*, D^*) = \arg \min_{E, D} \sum_{i=1}^n \|x_i - DEx_i\|_2^2 \quad (78)$$

对于 E^T 和 D 的列向量 e_j, d_j , 令 $z_{ij} = e_j^T x_i$ 化为

$$\sum_{i=1}^n \left\| x_i - \sum_{j=1}^k z_{ij} d_j \right\|_2^2 \quad (79)$$

假设 d_j 正交, 得到 $z_{ij} = d_j^T x_i$, 即 $e_j = d_j$, 原问题化为

$$D^* = \arg \min_D \sum_{i=1}^n \|x_i - DD^T x_i\|_2^2, \text{s.t. } D^T D = I \quad (80)$$

令 $L = \sum_{i=1}^n \|x_i - DD^T x_i\|_2^2$, 得

$$\begin{aligned} L &= \text{tr}(X^T X) - \text{tr}(D^T X^T X D) = \\ &\quad \text{tr}(X^T X) - \sum_{j=1}^k d_j^T X^T X d_j \end{aligned} \quad (81)$$

原问题用拉格朗日法得

$$D^* = \arg \min_D - \sum_{j=1}^k d_j^T X^T X d_j + \sum_{j=1}^k \lambda_j (d_j^T d_j - 1) \quad (82)$$

$$\forall j, -2X^T X d_j + s \lambda_j d_j = 0 \Rightarrow X^T X d_j = \lambda_j d_j \quad (83)$$

D 为 $X^T X = \sum x_i x_i^T$ 的前 k 个标准化特征向量, 投影 $z = D^T x = (d_1^T x, \dots, d_k^T x)^T$, 反投影 $\hat{x} = Dz + \bar{x} - DD^T \bar{x}$

几何意义: 旋转(去相关)后取方差最大的几个分量. 尽可能保持最大方差

核 PCA 用 $\Phi(x)$ 代替 x , 相当于计算“相似性”

多维尺度分析 MDS 定义距离 $d_{ij} = dist(x_i, x_j)$ 问题为

$$\min_{z_1, \dots, z_n} \sum_i \sum_j (\|z_i - z_j\| - d_{ij})^2 \quad (84)$$

流形 全局非线性, 局部线性. 若两点为邻居, 用欧几里得距离. 若不是, 用测地距离 (连接两点且位于流形上的最短线段的长度)

ISOMAP 建立一个图, 顶点为数据, 邻居间连边, 边权为欧几里得距离. 测地距离通过最短路算法计算, 最后用 MDS

局部线性嵌入 LLE 定义 $W \in \mathbb{R}^{n \times n}$, 若 x_i, x_j 不是邻居则 $W_{i,j} = 0$, 优化 W 的其它元素

$$\min_W \sum_{i=1}^n \left\| x_i - \sum_j W_{i,j} x_j \right\|^2 \text{ s.t. } \sum_j W_{i,j} = 1 \quad (85)$$

再计算投影

$$\min_{z_1, \dots, z_n} \sum_{i=1}^n \left\| z_i - \sum_j W_{i,j} z_j \right\|^2 \quad (86)$$

K-MEANS 令 $\mathcal{K} = 1, \dots, k$, 聚类要找 $f : \mathbb{R}^p \rightarrow \mathcal{K}$, 其反函数 $g : \mathcal{K} \rightarrow \mathbb{R}^p$. g 可用 k 个常向量 c_1, \dots, c_k 表示, 称为 codebook, 每个向量称为 codeword. 用平方损失函数, 经验风险为

$$\mathcal{E}(f, c_1, \dots, c_k) = \sum_{i=1}^n \|x_i - c_{f(x_i)}\|_2^2 \quad (87)$$

K-MEANS 用启发式迭代算法优化 \mathcal{E} , 到收敛为止

1. 若 c 已知, $f(x_i) = \arg \min_j \|x_i - c_j\|_2^2$

2. 若 f 已知, $c_j = \frac{\sum_i I(f(x_i)=j)x_i}{\sum_i I(f(x_i)=j)}$

通常用多个不同的初始化训练, 取最好的. 可先过分类 (用更多的 c) 再后处理提升表现

高斯混合模型 GMM 第 j 簇服从高斯分布 $N(\mu_j, \Sigma_j)$. 令 X_i 为样本, 对应簇为 Z_i, Z_i 间 i.i.d.

$$P(Z_i) = \prod_{j=1}^k w_j^{I(z_i=j)}, \sum_{j=1}^k w_j = 1 \quad (88)$$

$$P(X_i | Z_i) = \prod_{j=1}^k (N(X_i; \mu_j, \Sigma_j))^{I(z_i=j)} \quad (89)$$

$$P(X_i) = \sum_{j=1}^k w_j N(X_i; \mu_j, \Sigma_j) \quad (90)$$

X_i i.i.d.

期望最大化算法 (EM) for GMM 已知参数 w_j, μ_j, Σ_j

$$P(Z_i = j|X_i) = \frac{w_j N(x_i; \mu_j, \Sigma_j)}{\sum_{j=1}^k w_j N(x_i; \mu_j, \Sigma_j)} \triangleq \gamma_{ij} \quad (91)$$

$$\begin{aligned} w_j &= \frac{\sum_i \gamma_{ij}}{n}, \mu_j = \frac{\sum_i \gamma_{ij} x_i}{\sum_i \gamma_{ij}} \\ \Sigma_j &= \frac{\sum_i \gamma_{ij} (x_i - \mu_j)(x_i - \mu_j)^\top}{\sum_i \gamma_{ij}} \end{aligned} \quad (92)$$

迭代(91)和(92)直到收敛

$$f(x_i) = \arg \max_j P(Z_i = j|X_i = x_i) = \arg \max_j \gamma_{ij} \quad (93)$$

K-MEANS 与 GMM K-MEANS 是 GMM 的特例, 认为 $w_j = 1/k, \Sigma_j = I, \gamma_{ij}$ 计算如下

$$\begin{aligned} \gamma_{i,j} &= 1, if P(Z_i = j|X_i) = \max_l P(Z_i = l|X_i) \\ &= 0, otherwise \end{aligned} \quad (94)$$

k-means 使用硬分配 (hard assignment), GMM-EM 用软分配, 因此 k-means 对于具有不同大小、密度或不规则形状的簇存在局限性

EM 解决带隐变量的最大似然估计问题. 观测变量 X , 隐变量 Z , 待估参数 θ

算法 1 EM 算法

-
- 1: $t \leftarrow 0$, initialize θ^0
 - 2: **repeat**
 - 3: E-step: $Q(\theta) = \mathbb{E}_{Z \sim P(Z|X=x, \theta^t)} [\log P(X, Z; \theta)]$
 - 4: M-step: $\theta^{t+1} = \arg \max_\theta Q(\theta)$
 - 5: **until** $\|\theta^{t+1} - \theta^t\| < \epsilon$
 - 6: $\hat{\theta} = \theta^{t+1}$
-

$$\begin{aligned} \log P(X; \theta) &= (\sum_z P(Z = z|X; \theta^t)) \log P(X; \theta) \\ &= \sum_z P(Z = z|X; \theta^t) \log P(X, Z; \theta) \\ &\quad - \sum_z P(Z = z|X; \theta^t) \log P(Z|X; \theta) \\ &\triangleq Q(\theta) + H(\theta) \end{aligned} \quad (95)$$

$H(\theta)$ 是 $P(Z|X; \theta^t)$ 和 $P(Z|X; \theta)$ 间的交叉熵, 有 $H(\theta) \geq H(\theta^t)$. 我们优化 $Q(\theta)$, 有 $Q(\theta^{t+1}) \geq Q(\theta^t)$. 因此有 $\log P(X; \theta^{t+1}) \geq \log P(X; \theta^t)$. EM 为贪心, 每一步 P 不减

非参数聚类

基于距离的聚类 凝聚聚类: 自底向上, 合并相近数据或簇; 分离聚类: 自顶向下, 通过切掉距离最长的边来分割子图

基于距离的聚类 Mean-shift: 用 Parzen 窗估计局部密度并计算局部均值, 将局部模式 (密度最高的点) 移到均值处; DBSCAN: 给定一个随机选择的数据, 找到它的最近邻居并估计局部密度; 如果密度足够高, 则将此数据及邻居设置为簇, 并尝试扩展簇, 直到到达低密度区域

嵌入 embedding 增加特征的维度, 或为对象构建高维特征向量

例: 评分预测, 设有 n 个电影和 m 个用户, 每部电影有 1 个嵌入向量 $m_i \in \mathbb{R}^p$, 每个用户有 1 个嵌入向量 $u_i \in \mathbb{R}^p$, 评分为 $r_{ij} = m_i^T u_j$, 评分矩阵为 $R = M^T U$, 为一个低秩矩阵. 若已知 R , 可用截断 SVD 得到 M, U 用于评分预测

例: 词嵌入, 可用 LDA 思路 (减小类内方差, 增大类间差别)

6 基于树的模型与集成学习

回归树桩 regression stump

$$f(x) = (\beta_1 - \beta_0) \text{sign}(w^T x + b) + \beta_0 \quad (96)$$

模型组合 线性组合线性模型等价于另一线性模型, 一般不如此组合. 若基模型表现较好且有多样性 (well and diversely), 则组合模型一定有提升.

保证 well and diversely 的方法: 训练数据多样性 (数据分割、特征分割、不同核); 训练方法多样性

性能和多样性存在矛盾

模型组合方法: 简单相加/投票 (bagging, boosting); 训练组合 (stacking: 每个基模型学一个特征, 再训练一个总的模型进行组合); 局部自适应组合 (树模型: 将输入空间分为若干子域, 每个基模型处理一个)

bootstrap aggregating(bagging) 使用 bootstrap sampling(自助抽样) 得到数据多样性: 给定数据集 $x^{(i)}|_{i=1}^n$, 进行 n 次带放回的均匀采样.

一个数据抽不到的概率为 $(1 - \frac{1}{n})^n$, 当 $n \rightarrow +\infty$, 有 $1/e$ 的数据抽不到. 使用一次自助抽样训练一个基模型再组合起来.

Boosting 多个基模型一个一个地训练, 组合起来的模型会一点一点变好.

Boosting for 回归

$$F_p(x) = \sum_{j=1}^p \beta_j f_j(x) \quad (97)$$

其中 f_j 为基模型, F_p 为总的模型. Boosting 中模型一个一个训练, 可考虑

$$F_j(x) = F_{j-1}(x) + f_j(x) \quad (98)$$

使用平方损失函数

$$\begin{aligned} L(f_j) &= \sum_{i=1}^n (y_i - F_j(x_i))^2 \\ &= \sum_{i=1}^n (y_i - F_{j-1}(x_i) - f_j(x_i))^2 \end{aligned} \quad (99)$$

令 $r_i = y_i - F_{j-1}(x_i)$, 则 f_j 在回归 $(x^{(i)}, r^{(i)})$, 即除 f_1 外, f_i 在回归残差

算法 2 AdaBoost Algorithm

Require: $(x_i, y_i) |_{i=1}^n, y_i \in +1, -1$

Ensure: $F_p(x) = \text{sign}(\sum_{j=1}^p \beta_j f_j(x))$

```

1: for  $j = 1, \dots, p$  do
2:   if  $j=1$  then
3:      $w_{ij} = 1/n$ 
4:   else
5:      $w_{ij} = w_{i,j-1} \exp(-y_i \beta_{j-1} f_{j-1}(x_i))$ 
6:      $w_{ij} = \frac{w_{ij}}{\sum_i w_{ij}}$ 
7:   用  $w_{ij}$  给第  $i$  个数据加权, 训练分类器  $f_j$ 
8:   计算加权错误率  $e_j = \sum_i w_{ij} I(y_i \neq f_j(x_i))$ 
9:    $\beta_j = \frac{1}{2} \ln \frac{1-e_j}{e_j}$ 

```

AdaBoost 在加权数据上训练的两种方法

1. 对 loss 加权, 如 $\sum_{i=1}^n w_{ij} (-y_i \ln q_i - (1 - y_i) \ln (1 - q_i))$
2. 无显式 loss, 可将 w_{ij} 作为概率, 对数据重采样

若 f_j 对 x_i 分类正确, 则权重下降 ($\times \exp(-\beta_j)$), 反之上升 ($\times \exp(\beta_j)$). f_{j+1} 将更关注分类错误的数据.

实际上 AdaBoost 使用指数损失函数, 设分类器 $y = \text{sign}(x) \in +1, -1$

$$L(f; x, y) = \exp(-y f(x)) \quad (100)$$

最小化 e_j 实际上就是在加权数据上训练一个基分类器, 指数损失函数也是 0-1loss 的一个上界

决策树 一棵树, 每个内部节点对应某些特征的条件, 每个叶节点表示一类 (分类) 或一个值 (回归)

算法 3 HA

Require: A set of training data $\mathcal{D} = \{x_i, y_i\}$

Ensure: A classification tree or regression tree T

```

1: function HA( $\mathcal{D}$ )
2:   if  $\mathcal{D}$  不用分裂 then
3:     return 叶节点
4:   else
5:     寻找一个条件来分裂
6:     将  $\mathcal{D}$  按条件分裂为  $\mathcal{D}_1, \mathcal{D}_2, \dots,$ 
7:      $T_1 = \text{HA}(\mathcal{D}_1), T_2 = \text{HA}(\mathcal{D}_2), \dots$ 
8:     建树, 条件为根,  $T_1, T_2, \dots$  为子树
9:   return 生成的树

```

Hunt's algorithm(HA)

分裂条件选取 贪心: 最小化当前经验风险

回归树: 若使用平方损失

$$\min_{j, t_j, \alpha_j, \beta_j} \sum_{i=1}^n (\alpha_j I(x_j^{(i)} < t_j) + \beta_j I(x_j^{(i)} > t_j) - y^{(i)})^2 \quad (101)$$

取 α_j 为 $\{y^{(i)} | x_j^{(i)} < t_j\}$ 的均值, β_j 同理

二元分类树: 设 p_0 为 0 的百分数, p_1 同理, 常用 3 个指标:

误分率: $\mathcal{E}(D) = \min(p_0, p_1)$

熵: $H(D) = -p_1 \log_2 p_1 - p_0 \log_2 p_0$

Gini 指数: $G(D) = 1 - p_1^2 - p_0^2$

使用获得信息量决定分裂几支, 定义如下:

$$r \triangleq \frac{H(D) - \sum_i \frac{|D_i|}{|D|} H(D_i)}{- \sum_i \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}} \quad (102)$$

防止过拟合 早停: 提前停止分裂, 即使还能分

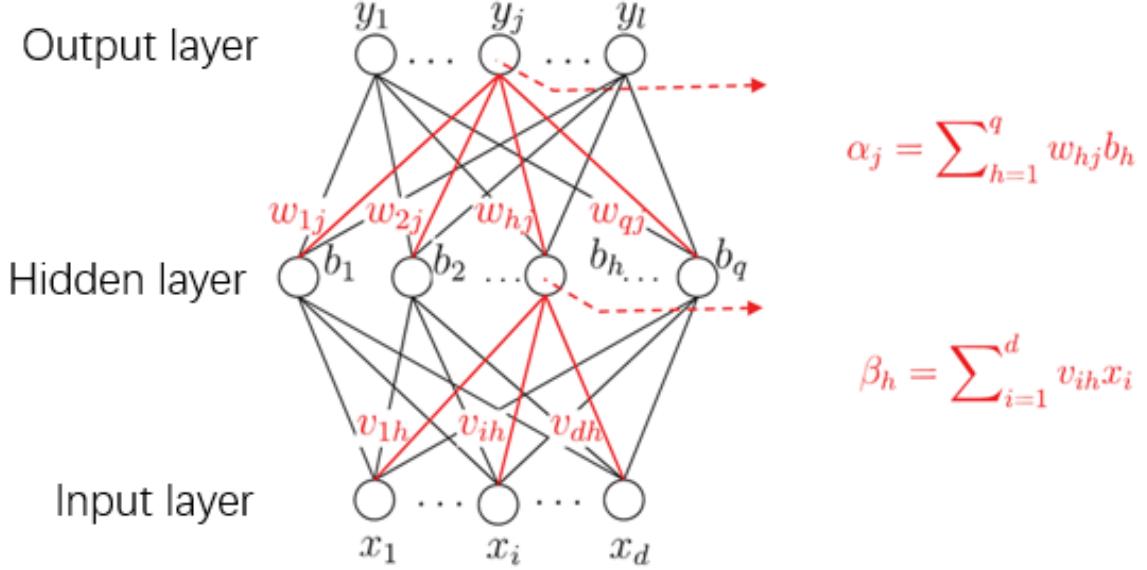
剪枝: 从训练好的树上移除树枝

一般来说剪枝优于早停, 剪枝考虑联合成本:

$$J(T) \triangleq \mathcal{E}(D, T) + \lambda |T| \quad (103)$$

\mathcal{E} 表示经验风险, $|T|$ 表示树的复杂度

7 图模型和深度学习



BP 网络模型 训练数据 $D = \{(x_k, y_k)\}, x_k \in \mathbb{R}^d, y_k \in \mathbb{R}^l$

待学习参数: 权重: v_{ih}, w_{hj} ; 偏置: γ_h, θ_j

梯度下降 **GD** 给定样本 (x^k, y^k) , 输出 \hat{y}^k

$$\begin{aligned} b_h &= f(\beta_h - \gamma_h), \beta_h = \sum_{i=1}^d v_{ih} x_i^k \\ \hat{y}_j^k &= f(\alpha_j - \theta_j), \alpha_j = \sum_{h=1}^q w_{hj} b_h \\ E_k &= \frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2 \end{aligned} \tag{104}$$

每个参数 ν 更新为

$$\begin{aligned} \nu &\leftarrow \nu + \Delta \nu \\ \Delta \nu &= -\eta \frac{\partial E_k}{\partial \nu} \end{aligned} \tag{105}$$

参数更新 (BP) 反向计算梯度

$$\begin{aligned}
\frac{\partial E_k}{\partial \hat{y}_j^k} &= \hat{y}_j^k - y_j^k \\
g_j &= \frac{\partial E_k}{\partial \alpha_j} = (\hat{y}_j^k - y_j^k) f'(\alpha_j - \theta_j) \\
\triangle w_{hj} &= -\eta g_j b_h \\
\triangle \theta_j &= \eta g_j \\
\frac{\partial E_k}{\partial b_h} &= \sum_{j=1}^l \frac{\partial E_k}{\partial \alpha_j} \frac{\partial \alpha_j}{\partial b_h} = \sum_{j=1}^l g_j w_{hj} \tag{106} \\
e_h &= \frac{\partial E_k}{\partial \beta_h} = \left(\sum_{j=1}^l g_j w_{hj} \right) f'(\beta_h - \gamma_h) \\
\triangle v_{ih} &= -\eta e_h x_i^k \\
\triangle \gamma_h &= \eta e_h
\end{aligned}$$

频繁更新参数，不同样本更新可能不一致，随机梯度下降 (SGD)

累计 BP

$$\Delta\nu = -\eta \frac{\partial E}{\partial \nu}, E = \sum_{k=1}^m E_k \quad (107)$$

标准梯度下降，参数更新不频繁，累计误差可能下降缓慢。实际应用中使用小批量 (small batches of) 数据

动量

$$\begin{aligned} \nu &\leftarrow \nu + \Delta\nu^{(t)} \\ \Delta\nu^{(t)} &= -\eta \frac{\partial E_k}{\partial \nu} + \alpha \Delta\nu^{(t-1)} \end{aligned} \quad (108)$$

使梯度下降更平滑

局部最小值 解决方法: 多次不同初始化; 模拟退火; 遗传算法

防止过拟合 使用验证集 (早停)

$$\text{正则化 } E = \frac{1}{m} \sum_{k=1}^m E_k + \omega \sum_i \nu_i^2$$

Dropout 和 DropConnect

8 统计学习理论

最小描述长度原理 MDL Kolmogorov 复杂度: 一个对象的 Kolmogorov 复杂度是输出为该对象的计算机程序的最短长度

例：“ababababababababababababababab”可用 print('ab'*16),Kolmogorov 复杂度在 Python 中不超过 14

随机性: 一个字符串是随机的, 当且仅当每个产生该字符串的计算机程序至少与字符串本身一样长

最小描述长度原理 (MDL): 统计学习任务是找到数据的最短描述

对于一个数据集 D 和假设空间 H , 可表示为:

$$h^* = \arg \min_{h \in H} L(h) + L(D|h) \quad (109)$$

例: 二元分类数据集 $\{(x^{(i)}, y^{(i)})|_{i=1}^n\}$, 多个模型 h_1, \dots, h_m , 有如下几种编码方式:(1) 编码每个 $x^{(i)}$;(2) 编码一些 h_j ;(3) 计算 $\hat{y}^{(k)} = \text{sign}(h_j(x^{(i)}))$, 编码集合 $\{i|y^{(i)} \neq \hat{y}^{(k)}\}$. 最小编码长度的模型最优.

若所有 h_j 和 i 均用固定长度编码, MDL 相当于最小化 0-1 loss 的经验风险

若 h_j 定长编码, i 变长编码, MDL 相当于给每组数据加权

若 h_j 变长编码, i 定长编码, MDL 相当于对参数有喜好

MDL 无需概率论的解释, 更加灵活